

**Revista Eletrônica  
Paulista de Matemática**

ISSN 2316-9664  
*preprint*

**Hitalo Cesar Alves**  
Instituto de Computação  
UNICAMP  
hitalo.c.a@gmail.com

**Diego Sebastian Ledesma**  
IMECC  
UNICAMP  
ledesma@unicamp.br

# **Estudo analítico e computacional de uma equação diferencial estocástica associada a um modelo de crescimento populacional**

Analytical and computational study of a stochastic  
differential equation associated to a population growth  
model

## **Resumo**

Neste trabalho estudamos uma equação diferencial estocástica associada a modelos de crescimento populacional. Em particular achamos sua solução analítica e a uma medida invariante para a equação. Logo simulamos por métodos computacionais a solução e comparamos com o obtido analiticamente.

**Palavras-chave:** Equações diferenciais estocásticas. Simulação de processos estocásticos. Modelo de crescimento populacional.

## **Abstract**

In this work, we study a stochastic differential equation associated with population growth models. In particular, we find its analytical solution and an invariant measure for the equation. Then we simulate the solution by computational methods and we compare it with the one obtained analytically.

**Keywords:** Stochastic differential equations. Simulation of stochastic processes. Population growth model.



# 1 Introdução

As equações diferenciais estocásticas são uma ferramenta muito importante na modelagem matemática de processos que ocorrem na natureza, fundamentalmente, porque permite a introdução de tudo aquilo que não é possível quantificar (por sua quantidade de variáveis ou sua pouca relevância para o processo) por meio de um ruído nos coeficientes do modelo.

O objetivo deste trabalho é dar uma ideia sobre como trabalhar com equações diferenciais estocásticas estudando a modo de exemplo, por métodos analíticos e computacionais, um caso em particular. Por isto, neste trabalho, consideramos uma equação diferencial estocástica não linear associada a modelos de crescimento populacional e que é dada por

$$dx_t = rx_t(k - \alpha x_t) dt + \beta x_t dB_t \quad x_0 = N$$

para  $N, r, k$ , e  $\alpha \in [0, \infty]$  e tais que  $2rk > \beta^2$ . Esta é uma pequena variação de um modelo proposto por Polansky(1979) e nos permite, por meio de variações do parâmetro  $\alpha$ , estudar um conjunto de equações que incluem o modelo já mencionado de Polansky ( $\alpha = 1$ ) e o bem conhecido modelo padrão de crescimento populacional com ruído (OKSENDAL, 1997) para ( $\alpha = 0$ ).

O artigo será dividido em três partes. Na primeira parte faremos uma breve revisão da teoria básica de equações diferenciais estocásticas. Logo depois introduzimos a equação diferencial estocástica a ser trabalhada e provamos o resultado principal do trabalho que diz sobre a existência de solução e da medida invariante para esta. Finalmente, na terceira parte, fazemos uma breve revisão da teoria de simulações para equações diferenciais estocásticas pelo modelo de Euler e fazemos a simulação da solução utilizando a linguagem Python. Logo, comparamos os resultados modelados com os obtidos analiticamente.

Este trabalho faz parte do estudo de Iniciação Científica do primeiro autor.

# 2 Breve revisão de cálculo estocástico

Nesta seção pretendemos dar brevemente a fundamentação teórica do trabalho. Expomos brevemente os resultados principais e indicamos as referências onde podem ser achados para uma revisão mais aprofundada do tópico.

Fixamos, ao longo do trabalho, um espaço de probabilidade filtrado  $(\Omega, \{\mathcal{F}_t\}_{t \in I}, \mathbb{P})$  para  $I \subset \mathbb{R}$ .

**Definição 1** Se  $(\Omega, \mathcal{F}, \mathbb{P})$  é um espaço de probabilidade, uma variável aleatória real  $X$  é uma função  $\mathcal{F}_t$  mensurável  $X : \Omega \rightarrow \mathbb{R}$ . Dada uma variável aleatória  $X : \Omega \rightarrow \mathbb{R}$  definimos a sua lei  $F_X : \mathbb{R} \rightarrow [0, 1]$  como sendo a medida de probabilidade sobre  $\mathbb{R}$  tal que

$$F_X(U) = \mathbb{P}[X^{-1}(U)]$$

Seja  $X : \Omega \rightarrow \mathbb{R}$  uma variável aleatória e  $f : \mathbb{R} \rightarrow \mathbb{R}$ , definimos o seu valor esperado (ou esperança) de  $f(X)$  como o número  $\mathbb{E}[f(X)]$  obtido da seguinte forma

$$\mathbb{E}[f(X)] = \int_{\Omega} f(X) d\mathbb{P} = \int_{\mathbb{R}} f(x) dF_X(x).$$

**Definição 2** Um processo estocástico real é um conjunto de variáveis aleatórias  $\{X_t : \Omega \rightarrow \mathbb{R}\}$  indexadas por um parâmetro  $t$  tomando valores num conjunto ordenado (usualmente  $\mathbb{N}$  ou  $\mathbb{R}$ )



74 Neste trabalho vamos nos concentrar no caso em que o parâmetro  $t$  toma valores em um  
75 intervalo  $I \subset \mathbb{R}$ . O processo estocástico mais importante para os nossos estudos é o Movimento  
76 Browniano. Este é o processo  $\{B_t\}_{t \geq 0}$  com as seguintes propriedades:

- 77 •  $B_0 = 0$
- 78 • a função  $t \rightarrow B_t$  é contínua em  $t$ ,
- 79 • o processo  $\{B_t\}_{t \geq 0}$  tem incrementos estacionários e independentes, os incrementos  $B_{t+s} -$   
80  $B_s$  tem por lei a distribuição normal com média 0 e variância  $t$ . Ou seja:  $B_{t+s} - B_s \sim$   
81  $N(0, t)$ .

82 É possível mostrar, utilizando o teorema de continuidade de Kolmogorov (ver, por exemplo,  
83 o capítulo 2 do livro de OKSENDAL, B.), que o movimento browniano pode ser construído  
84 de forma tal que os seu caminhos, isto é, as funções

$$t \in [0, \infty) \rightarrow X_t(\omega) \in \mathbb{R},$$

85 sejam contínuos. Então, cabe a pergunta se é possível integrar com respeito a  $B_t$ . Nesse  
86 sentido é definida a integral de Itô, como sendo

$$\int_0^t f(s, B_s) dB_s = \lim_{n \rightarrow \infty} \sum_{t_i \in \tau_n, t_i \leq t} f(s_i, B_{t_i})(B_{t_{i+1}} - B_{t_i}) \quad (\text{limite em } L^2(\Omega, \mathbb{P}))$$

87 onde  $f : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$  é uma função  $C^\infty$ ,  $B_t$  é o movimento browniano e  $\{\tau_n\}$  uma sequência  
88 de partições de  $[0, t]$  tais que

$$|\tau_n| = \sup_n |t_{i+1} - t_i| \rightarrow 0 \quad \text{se } n \rightarrow \infty.$$

89 É possível ver que

- 90 • a integral de Itô é independente da sequência de partições,
- 91 • o processo

$$A_t = \int_0^t f(s, B_s) dB_s$$

92 é um processo estocástico  $F_t$  mensurável para cada  $t$  com

$$\mathbb{E}[A_t] = 0,$$

93 para todo  $t$  (SONDERMAN, 2006).

94 A integral de Itô não obedece a fórmula de mudança de variáveis. No seu lugar temos a  
95 bem conhecida **fórmula de Itô** que é o equivalente estocástico ao teorema fundamental do  
96 cálculo. Apresentamos aqui uma versão simplificada desta:

97 **Teorema 3** *Seja  $f : \mathbb{R} \times \mathbb{R}^n \rightarrow \mathbb{R}$  uma função  $C^\infty$  e  $\{B_t\}$  o movimento browniano iniciando*  
98 *em  $B_0 = x$  então*

$$f(t, B_t) = f(0, x) + \int_0^t \partial_x f(s, B_s) dB_s + \int_0^t \left[ (\partial_t f)(s, B_s) + \frac{1}{2} \partial_x^2 f(s, B_s) \right] ds,$$

99 ou na forma diferencial

$$df(t, B_t) = \partial_x f(t, B_t) dB_t + \left[ (\partial_t f)(t, B_t) + \frac{1}{2} \partial_x^2 f(t, B_t) \right] dt,$$



Para uma prova do resultado consultar o capítulo 3 do livro de OKSENDAL, B.

**Exemplo 1** Em particular, se  $f : \mathbb{R} \times \mathbb{R}^2 \rightarrow \mathbb{R}$  dada por

$$f(t, x) = g(t)h(t, x)$$

onde  $g(t)$  é um processo que admite derivada com respeito a  $t$  e  $h$  uma função  $C^\infty$ , temos que a fórmula de Itô garante

$$f(t, B_t) = f(0, 0) + \int_0^t \left( \dot{g}(s) + g(s)\partial_t h(s, B_s) + \frac{1}{2}g(s)\partial_x^2 h(s, B_s) \right) ds + \int_0^t g(s)\partial_x h(s, B_s) dB_s.$$

ou na forma diferencial

$$df(t, B_t) = h(t, B_t)dg(t) + g(t) \left( \partial_t h(t, B_t) + \frac{1}{2}\partial_x^2 h(t, B_t) \right) dt + g(t)\partial_x h(t, B_t) dB_t$$

Uma vez conhecida a integral de Itô, definimos a **Equação diferencial estocástica no sentido Itô** (EDE) a valores reais como sendo uma equação da forma

$$dx_t = X_0(t, x_t) dt + X_1(t, x_t) dB_t, \quad x_0 = x, \quad (1)$$

onde  $X_i : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$  são funções  $C^\infty$ . Esta equação, embora escrita na forma diferencial, deve ser entendida na forma integral. Isso é o conteúdo da seguinte definição.

**Definição 4** Seja  $(s, x) \in [0, T] \times \mathbb{R}^n$ . Um processo estocástico contínuo  $x_t$ , para  $t \in [s, T]$ , a valores em  $\mathbb{R}$  é dito um solução (forte) da equação diferencial estocástica (1), com condição inicial  $x_s = x$  se, e somente se, satisfaz

$$x_t = x + \int_s^t X_0(r, x_r) dr + \int_s^t X_1(r, x_r) dB_r.$$

Em geral, garantir a existência e unicidade de soluções de equações diferenciais estocásticas não é fácil. Há resultados que garantem que se os coeficientes da equação são localmente Lipschitz é possível garantir a existência da solução (KUNITA, 1997). No entanto, achar uma forma explícita da solução pode ser uma tarefa muito difícil.

Se  $x_t$  é solução da equação 1 então podemos provar, como consequência da fórmula de Itô, que para toda função  $f \in C^2(\mathbb{R})$  temos

$$f(x_t) = f(x_0) + \int_0^t \left( X_0(r, x_r)\partial_x f(x_r) + \frac{1}{2}X_1(r, x_r)^2\partial_x^2 f(x_r) \right) dr + \int_0^t X_1(r, x_r)\partial_x f(x_r) dB_r,$$

ou, na forma diferencial,

$$df(x_t) = \left( X_0(t, x_t)\partial_x f(x_t) + \frac{1}{2}X_1(t, x_t)^2\partial_x^2 f(x_t) \right) dt + X_1(t, x_t)\partial_x f(x_t) dB_t.$$

Para mais detalhes, consultar os capítulos 3 e 4 de OKSENDAL, B.

Dada a equação diferencial estocástica 1 como acima, assuma que existe uma aplicação

$$\phi : [0, \infty) \times \mathbb{R} \times \Omega \rightarrow \mathbb{R},$$



121 contínua nas primeiras duas variáveis, e tal que para cada  $x$  dá a solução

$$x_t(\omega) = \phi(t, x, \omega)$$

122 da equação com  $x_0 = x$ . Tal aplicação é comumente chamada de fluxo solução. Uma medida  
123 de probabilidade

$$\mu = \rho(x) \, dx$$

124 é dita invariante para a equação 1 se

$$\mathbb{E} \left[ \int_{\mathbb{R}} f(\phi(t, x, \omega)) \rho(x) \, dx \right] = \int_{\mathbb{R}} f(x) \rho(x) \, dx$$

125 para toda  $f \in C^\infty(\mathbb{R})$  e  $t \in [0, \infty)$ .

126 Vamos a interpretar qual o significado da medida invariante. Para isto, considere que para  
127 a equação 1 existe um ponto  $y_0$  tal que

$$X_0(t, y_0) = 0, \quad X_1(t, y_0) = 0.$$

128 Neste caso, o processo

$$x_t = \phi(t, y_0, \omega) = y_0$$

129 é solução natural da equação para  $x_0 = y_0$ . Estes pontos são chamados de pontos de equilíbrio  
130 para a equação. Em particular temos que medida dada pela delta de dirac  $\delta_{y_0}(x)$  é uma medida  
131 invariante para a equação pois

$$\begin{aligned} \mathbb{E} \left[ \int_{\mathbb{R}} f(\phi(t, x, \omega)) \delta_{y_0}(x) \, dx \right] &= \mathbb{E} [f(\phi(t, y_0, \omega))] \\ &= f(y_0) \\ &= \int_{\mathbb{R}} f(x) \delta_{y_0}(x) \, dx. \end{aligned}$$

132 Assim, de forma geral, as medidas invariantes são generalizações dos pontos de equilíbrio da  
133 equação estocástica.

134 Podemos caracterizar as medidas invariantes utilizando um operador diferencial de segunda  
135 ordem

$$LV(x) = X_0(t, x) \partial_x V(x) + \frac{1}{2} X_1(t, x)^2 \partial_x^2 V(x).$$

136 para toda função  $V$  diferenciável. Este é o conteúdo do seguinte resultado.

137 **Lema 2** Uma medida de probabilidade  $\mu(x) = \rho(x) \, dx$  é invariante para a equação 1 se

$$\int_{\mathbb{R}} Lf(x) \rho(x) \, dx = 0, \tag{2}$$

138 para toda  $f$  de classe  $C^\infty$  e limitada.

139 *Demonstração.* Seja  $f$  de classe  $C^\infty$  e limitada e  $\phi(t, x, \cdot)$  o fluxo solução da equação 1.  
140 Observamos que  $f \circ \phi(t, x, \cdot)$  é  $C^\infty$  e limitada.

141 Consideramos a identidade

$$\mathbb{E}[Lf(\phi(t, x, \cdot))] = L\mathbb{E}[f(\phi(t, x, \cdot))]$$



142 cuja prova pode ser encontrada em Oksendal(1997, p. 134,135).

143 Da fórmula de Itô temos

$$f(\phi(t, x, \cdot)) = f(x) + \int_0^t f(\phi(s, x, \cdot)) dB_s + \int_0^t Lf(\phi(s, x, \cdot)) ds$$

144 Multiplicando por  $\rho(x)$  e integrando obtemos

$$\begin{aligned} \int_{\mathbb{R}} f(\phi(t, x, \cdot)) \rho(x) dx &= \int_{\mathbb{R}} f(x) \rho(x) + \int_0^t \left( \int_{\mathbb{R}} f(\phi(s, x, \cdot)) \rho(x) dx \right) dB_s \\ &\quad + \int_0^t \int_{\mathbb{R}} (Lf(\phi(s, x, \cdot)) \rho(x)) dx ds \end{aligned}$$

145 Tomando esperança aos dois lados da identidade e utilizando que a medida  $\mu(x) = \rho(x) dx$  é  
146 de probabilidade, vemos que ela será invariante se, e só se, temos

$$\int_0^t \int_{\mathbb{R}} L\mathbb{E}[f(\phi_s(x, \cdot))] \rho(x) dx ds = \int_0^t \int_{\mathbb{R}} \mathbb{E}[Lf(\phi_s(x, \cdot))] \rho(x) dx ds = 0.$$

147 Portanto a medida será invariante se, e somente se,

$$\int_{\mathbb{R}} Lf(x) \rho(x) dx = 0,$$

148 para toda  $f$  de classe  $C^\infty$  e limitada.

149

□

150

151 Mais ainda, podemos ver que para a medida invariante  $\mu$  vale o seguinte resultado, de  
152 acordo com o Teorema 4.3 de Khasminskii(2011) ou o teorema 5.9 de Gard(1988)

153 **Teorema 5** *Assuma que existe um conjunto  $U$  aberto e limitado de  $\mathbb{R}$  com fronteira regular*  
154  *$B$  tal que:*

155 a-  $X_1(t, x)|_U > 0$

156 b- Se  $x \in U^C$  o tempo de saída  $\tau$  de  $U^C$  é finito. Isto é, se

$$\tau^x = \inf\{t, \phi(t, x, \omega) \in U\},$$

157 então  $\mathbb{E}[\tau^x] < \infty$ . Mais ainda,  $\sup_{x \in K} \mathbb{E}[\tau^x] < \infty$  para todo compacto  $K \subset \mathbb{R}$ .

158 c- Se  $\mu$  é a medida invariante associada à 1 então  $\mu(B) = 0$ .

159 Então

$$\lim_{t \rightarrow \infty} \mathbb{P}[x_t \in A] = \int_A d\mu.$$

160 Este resultado é muito interessante pois, basicamente, diz que se a equação satisfaz as  
161 hipóteses podemos estudar o que acontece (em probabilidade) com  $x_t$  quando  $t \rightarrow \infty$ .

162 Passamos a estudar agora condições sobre a equação 1 que garantem que esta satisfaz as  
163 hipóteses do teorema. Para isso, fazemos uma redução na equação 1, em particular pedimos  
164 que os termos que dirigem a equação sejam independentes do tempo, isto é,

$$X_0(t, x) = X_0(x) \quad \text{e} \quad X_1(t, x) = X_1(x) > 0.$$



165 Desta forma, a equação satisfaz a—. Para mostrar b—, considere agora a função  $v$  de classe  
166  $C^2$  tal que

$$Lv(x) = X_0(x)\partial_x v(x) + \frac{1}{2}X_1(x)^2\partial_x^2 v(x) = -1.$$

167 A escolha do valor  $-1$  aqui é por conveniência, podendo ser escolhido um valor  $k < 0$ .  
168 Podemos ver que

$$\begin{aligned} v(x) &= -\exp\left(-\int_{y_0}^x \frac{2X_0(y)}{X_1(y)^2} dy\right) \int_{y_0}^x \frac{1}{X_1(z)^2} \exp\left(\int_{y_0}^z \frac{2X_0(y)}{X_1(y)^2} dy\right) dz \\ &= \int_x^{y_0} \frac{1}{X_1(z)^2} \exp\left(-\int_z^x \frac{2X_0(y)}{X_1(y)^2} dy\right) dz \end{aligned}$$

169 para algum  $y_0 \in \mathbb{R}$ , satisfaz a equação. Aplicamos agora a formula de Itô a  $v(x_t)$  para obter

$$\begin{aligned} v(x_T) &= v(x_0) + \int_0^T \left( X_0(x)\partial_x v(x) + \frac{1}{2}X_1(x)^2\partial_x^2 v(x) \right) dt + \int_0^T X_1(x_t)\partial_x v(x) dB_t \\ &= v(x_0) - \int_0^T 1 dt + \int_0^T X_1(x_t)\partial_x v(x) dB_t. \end{aligned}$$

170 Então, se  $\tau$  é a variável aleatória definida acima, vemos que

$$\mathbb{E}[v(x_\tau)] = v(x_0) - \mathbb{E}[\tau].$$

171 Portanto, se  $v$  é uma função diferenciável e não negativa em  $U^C$ , vemos que

$$\mathbb{E}[\tau] \leq v(x_0) < \infty$$

172 e, consequentemente, satisfaz as condições  $a$  e  $b$  do teorema (conforme teorema 3.11 de Khas-  
173 minskii(2011)). Isto será exemplificado na próxima seção para um caso particular.

### 174 3 Modelo estocástico de crescimento populacional

175 Nesta seção vamos aplicar os conceitos e resultados introduzidos na seção anterior para  
176 uma equação diferencial estocástica associada um modelo populacional .

177 Consideramos a equação diferencial estocástica não linear dada por

$$dx_t = rx_t(k - \alpha x_t) dt + \beta x_t dB_t, \quad x_0 = N, \quad (3)$$

178 para  $N, r, k$ , e  $\alpha \in [0, \infty]$  e tais que  $2rk > \beta^2$ .

179 Esta equação é bem conhecida na literatura quando reduzida aos seguintes dois casos

- 180 • O caso em que  $\alpha = 0$  a equação se reduz à equação que modela o crescimento populacional  
181 estandar em que  $rk$  é a taxa de crescimento e  $\beta \in \mathbb{R}$  é a medida do tamanho do ruído  
182 do ambiente.
- 183 • O caso em que  $\alpha = 1$  a equação descreve o crescimento populacional em ambientes  
184 super-lotados. Nesse caso a constante  $k > 0$  é a capacidade do ambiente,  $r > 0$  é a  
185 medida da qualidade do ambiente e  $\beta \in \mathbb{R}$  é a medida do tamanho do ruído do ambiente.



186 Comparando a equação 1 com a equação 3 temos

$$X_0(t, x) = rx(k - \alpha x) \quad \text{e} \quad X_1(t, x) = \beta x.$$

187 Em particular, o operador  $L$  é definido por

$$Lv(x) = rx(k - \alpha x)\partial_x v(x) + \frac{1}{2}\beta^2 x^2 \partial_x^2 v(x),$$

188 para toda função  $v$  de classe  $C^\infty$ . No caso em que  $\alpha = 0$  a solução do problema  $Lv = -1$  é

$$v(x) = \frac{-2}{2rk - \beta^2} \ln(x),$$

189 que é uma função que não é positiva definida portanto nada podemos garantir quanto à  
190 aplicação do teorema 5. No entanto, para  $\alpha > 0$  temos que a função

$$v(x) = \frac{1}{\beta^2} x^{\left(\frac{2rk}{\beta^2}\right)} e^{-\left(\frac{2r\alpha}{\beta^2} x\right)} \int_x^\infty z^{\left(\frac{2rk}{\beta^2}\right)} e^{-\left(\frac{2r\alpha}{\beta^2} z\right)} dz.$$

191 é positiva e satisfaz  $Lv = -1$  em  $(0, \infty)$ .

192 Agora podemos provar o resultado principal do trabalho.

193 **Teorema 6** *A equação diferencial estocástica 3 tem por solução*

$$x_t = \frac{e^{(rk - \frac{1}{2}\beta^2)t + \beta B_t}}{\frac{1}{N} + r\alpha \int_0^t e^{(rk - \frac{1}{2}\beta^2)s + \beta B_s} ds}.$$

194 Mas ainda, se  $\alpha > 0$ , a equação admite uma medida invariante da forma  $\mu = \rho(x) dx$  para

$$\rho(x) = \frac{1}{\Gamma\left(\frac{2rk}{\beta^2} - 1\right)} \left(\frac{2r\alpha}{\beta^2}\right)^{\left(\frac{2rk}{\beta^2} - 1\right)} \exp\left(-\frac{2r\alpha}{\beta^2} x\right) x^{\left(\frac{2rk}{\beta^2} - 2\right)},$$

195 donde  $\Gamma$  é a função gamma que generaliza a função fatorial.

196 *Demonstração.* Propomos como solução um processo

$$x_t = f(t)e^{(rk - \frac{1}{2}\beta^2)t + \beta B_t}$$

197 Para  $f(t)$  um processo que admita derivada com respeito a  $t$  e tal que  $f(0) = N$ . Então,  
198 calculamos

$$\begin{aligned} dx_t &= df(t) e^{(rk - \frac{1}{2}\beta^2)t + \beta B_t} + f(t)(rk dt + \beta dB_t) e^{(rk - \frac{1}{2}\beta^2)t + \beta B_t} \\ &= df(t) e^{(rk - \frac{1}{2}\beta^2)t + \beta B_t} + rk x_t dt + \beta x_t dB_t. \end{aligned}$$

199 Comparando com a equação original, temos que  $f(t)$  deve satisfazer

$$df(t) = r\alpha f(t)^2 e^{(rk - \frac{1}{2}\beta^2)t + \beta B_t} dt.$$





Portanto,

$$\frac{1}{f(t)} = \frac{1}{N} + r\alpha \int_0^t e^{(rk - \frac{1}{2}\beta^2)s + \beta B_s} ds.$$

Juntando as partes temos então que a solução é

$$x_t = \frac{e^{(rk - \frac{1}{2}\beta^2)t + \beta B_t}}{\frac{1}{N} + r\alpha \int_0^t e^{(rk - \frac{1}{2}\beta^2)s + \beta B_s} ds}.$$

O fluxo solução é dado pelo mapa

$$\phi(t, x, \omega) = \left( \frac{e^{(rk - \frac{1}{2}\beta^2)t + \beta B_t}}{\frac{1}{x} + r\alpha \int_0^t e^{(rk - \frac{1}{2}\beta^2)s + \beta B_s} ds} \right) (\omega)$$

Observamos que a solução assume valores em  $(0, \infty)$  então, é de esperar que a medida invariante tenha suporte neste conjunto. Para achá-la, observamos que

$$Lf(x) = rx(k - \alpha x)\partial_x f(x) + \frac{1}{2}\beta^2 x^2 \partial_x^2 f(x).$$

Então, se  $\mu = \rho(x) dx$  é invariante, temos que

$$\int_{\mathbb{R}} \left( rx(k - \alpha x)\partial_x f(x) + \frac{1}{2}\beta^2 x^2 f \partial_x^2 f(x) \right) \rho(x) dx = 0$$

para toda função  $f$  de classe  $C^\infty$  e limitada. Assumindo que  $\rho(x)$  é  $C^2$ , pelo fato de  $\rho(x)$  ser a densidade de uma medida de propabilidade, temos que

$$\lim_{x \rightarrow \pm\infty} \rho(x) = 0.$$

Agora, utiliando integração por partes e a limitação de  $f$  vemos que

$$\begin{aligned} \int_{\mathbb{R}} \left( rx(k - \alpha x)\partial_x f(x) + \frac{1}{2}\beta^2 x^2 f(x) \right) \rho(x) dx &= \int_{\mathbb{R}} \partial_x f(x) (rx(k - \alpha x)\rho(x)) dx \\ &\quad + \int_{\mathbb{R}} \left( \frac{1}{2}\beta^2 x^2 \rho(x) \right) \partial_x^2 f(x) dx \\ &= \int_{\mathbb{R}} \partial_x f(x) (rx(k - \alpha x)\rho(x)) dx \\ &\quad + \int_{\mathbb{R}} \partial_x^2 f(x) \left( \frac{1}{2}\beta^2 x^2 \rho(x) \right) dx \\ &= - \int_{\mathbb{R}} f(x) \partial_x (rx(k - \alpha x)\rho(x)) dx \\ &\quad + \int_{\mathbb{R}} f(x) \partial_x^2 \left( \frac{1}{2}\beta^2 x^2 \rho(x) \right) dx \end{aligned}$$

De onde obtemos que

$$\int_{\mathbb{R}} \left( rx(k - \alpha x)\partial_x f(x) + \frac{1}{2}\beta^2 x^2 f(x) \right) \rho(x) dx = 0$$



210 é equivalente a

$$\int_{\mathbb{R}} \left( \partial_x (rx(k - \alpha x)\rho(x)) - \frac{1}{2}\beta^2 \partial_x^2 (x^2 \rho(x)) \right) f(x) dx = 0$$

211 para toda  $f$  de classe  $C^\infty$  e limitada.

212 Portanto  $\rho(x)$  resolve a equação

$$\partial_x (rx(k - \alpha x)\rho(x)) - \frac{1}{2}\beta^2 \partial_x^2 (x^2 \rho(x)) = 0.$$

213 Para resolvê-la, denotamos por

$$b(x) = rx(k - \alpha x), \quad \eta(x) = \frac{\beta^2}{2}x^2,$$

214 então a equação pode ser simplificada a

$$\partial_x (b(x)\rho(x) - \partial_x (\eta(x)\rho(x))) = 0$$

215 Então

$$b(x)\rho(x) - \partial_x (\eta(x)\rho(x)) = A$$

216 para  $A$  constante. Em particular para  $A = 0$ , podemos escrever

$$\partial_x (\ln (\eta(x)\rho(x))) = \frac{b(x)}{\eta(x)}$$

217 De onde tiramos que, se  $\alpha > 0$ , temos

$$\rho(x) = \frac{K}{\eta(x)} \exp \left( \int \frac{b(x)}{\eta(x)} dx \right)$$

218 Substituindo pelos dados conhecidos, temos que

$$\rho(x) = K \exp \left( -\frac{2r\alpha}{\beta^2} x \right) x^{\left(\frac{2rk}{\beta^2} - 2\right)}$$

219 para  $K$  uma constante de renormalização. A forma de  $\rho$  é similar com a da distribuição

220 Gamma

$$h(x, a, b) = \frac{b^a x^{a-1} e^{-bx}}{\Gamma(a)}$$

221 Portanto

$$\rho(x) = h(x, a, b)$$

222 para

$$a = \frac{2rk}{\beta^2} - 1, \quad b = \frac{2r\alpha}{\beta^2} \quad \text{e} \quad K = \frac{b^a}{\Gamma(a)}.$$

223

□

224



Uma vez que conhecemos a medida invariante podemos calcular, utilizando o teorema 5, qual a probabilidade de que um processo assumira valores em um determinado conjunto  $A$ , quando o tempo é suficientemente grande, simplesmente calculando

$$\lim_{t \rightarrow \infty} \mathbb{P}[x_t \in A] = \int_A \rho(x) dx.$$

Observamos que isto só será possível se  $\alpha > 0$  pois o caso  $\alpha = 0$  não satisfaz o item  $b-$  do teorema 5. Para  $\alpha > 0$  temos que o máximo de  $\rho(x)$  é atingido para

$$x_1 = \frac{rk - \beta^2}{r\alpha}$$

Então, calculando a integral da distribuição Gamma com os coeficientes como acima, podemos achar, para todo  $\epsilon > 0$ , um intervalo da forma  $A = (x_1 - a, x_1 + b)$  para  $a, b > 0$  tais que

$$\lim_{t \rightarrow \infty} \mathbb{P}[x_t \in A] = 1 - \epsilon.$$

Mais ainda, do que sabemos da distribuição gamma, podemos afirmar, qualitativamente, que o valor esperado de  $x_\infty$  e a variancia  $\sigma$  são

$$\mathbb{E}[x_\infty] = \frac{2rk - \beta^2}{2r\alpha}, \quad \text{e} \quad \sigma(x_\infty) = \frac{\beta^2(2rk - \beta^2)}{(2r\alpha)^2}.$$

Temos provado assim o seguinte resultado.

**Corolário 7** Nas hipóteses do teorema 6 e com  $\alpha > 0$  temos que para todo  $\epsilon > 0$  existem reais positivos  $a, b$  tais que se  $A = (x_1 - a, x_1 + b)$  para

$$x_1 = \frac{rk - \beta^2}{r\alpha}$$

então,

$$\lim_{t \rightarrow \infty} \mathbb{P}[x_t \in A] = 1 - \epsilon.$$

## 4 Comparação analítica-computacional

Nessa terceira parte estudamos a simulação da equação diferencial estocástica:

$$dx_t = rx_t(k - \alpha x_t)dt + \beta x_t dB_t, \quad x_0 = N,$$

para  $N, r, k$ , e  $\alpha \in [0, \infty)$  e tais que  $2rk > \beta^2$ .

Começamos fazendo a simulação do movimento browniano. Observamos que esta deve ter as propriedades apresentadas na secção 2, isto é, deve ser uma função  $\{B_t : \Omega \rightarrow \mathbb{R}\}$  tal que

- $B_0 = 0$
- se  $t_0 = 0 < t_1 < t_2 < \dots < t_l$ , então o incremento  $B_{t_i} - B_{t_{i-1}}$  é independente com  $B_{t_i} - B_{t_{i-1}} \sim N(0, t_i - t_{i-1})$ . Ou seja,  $B_{t_i} - B_{t_{i-1}}$  não depende de  $B_{t_{i-1}}$ .



247 Para simular uma função desse tipo, podemos gerar uma sequência de variáveis aleatórias  
 248 independentes  $(S_j)_j$  e tais que  $S_j \sim N(0, 1)$ . Mas como estamos trabalhando com o compu-  
 249 tador, queremos definir e simular  $l$  valores de tempos  $t_0 = 0 < t_1 < t_2 < \dots < t_{l-1}$  gerando  
 250 um vetor  $(B_{t_1}, B_{t_2}, \dots, B_{t_{l-1}})$ . Isto pode ser feito de forma simples uma vez que os incrementos  
 251 são independentes. A função  $B_t$  é então definida computacionalmente da seguinte forma:

$$\begin{aligned} B_{t_1} &= \sqrt{t_1} S_1, \\ B_{t_2} &= B_{t_1} + \sqrt{(t_2 - t_1)} S_2 = \sqrt{t_1} S_1 + \sqrt{(t_2 - t_1)} S_2, \\ B_{t_j} &= \sum_{i=1}^j \sqrt{(t_i - t_{i-1})} S_i, \\ B_{t_{j+1}} &= B_{t_j} + \sqrt{(t_{j+1} - t_j)} S_{j+1}. \end{aligned}$$

252 Na figura 1 é mostrada a simulação obtida do movimento browniano para 10.000 caminhos  
 253 diferentes com  $l = 100$  valores de tempo e

$$t_{j+1} - t_j = 1, \quad \forall j \in \{0, 1, \dots, 97, 98\}.$$




Figura 1: 10000 caminhos movimentos browniano com  $l = 100$

254 Uma vez que podemos simular o movimento browniano passamos construir uma simulação



da equação diferencial estocástica 3 utilizando o seguinte esquema de Euler:

$$x_{t_{n+1}} = x_{t_n} + rx_{t_n}(k - \alpha x_{t_n})(t_{n+1} - t_n) + \beta x_{t_n}(B_{t_{n+1}} - B_{t_n})$$

No nosso trabalho vamos simular a equação utilizando o esquema de Euler com a simulação do movimento browniano feita acima. É possível ver que o esquema de Euler fornece uma boa aproximação para estudar quantidades que dependem da lei do processo  $x_t$  que é solução da equação a ser simulada. A aproximação é melhor quanto maior é a discretização do tempo. No nosso caso discretizamos o tempo em intervalos de comprimento 1. No entanto, podem ser feitas discretizações mais precisas diminuindo o comprimento deste intervalo. O resultado que garante esta última afirmação é o teorema de Turelli que está apresentado em Gard(1988, p. 166,167). Descrevemos a seguir as ideias básicas deste resultado.

Considere uma equação diferencial estocástica da forma

$$dx_t = X_0(x_t)dt + X_1(x_t)dB_t$$

em que  $X_0$  e  $X_1$  são contínuas, diferenciáveis em  $[0, \infty)$  e que satisfazem

- $X_0(0) = X_1(0) = 0$ .
- existe  $R > 0$  tal que se  $x > R$  então  $X_0(x) < 0$
- se  $x \neq 0$  então  $X_1(x) \neq 0$

Assuma que para qualquer solução em  $[0, \infty)$  o limite no  $\infty$  é inatingível, isto é

$$\mathbb{P} \left[ \lim_{t \rightarrow \infty} x_t = \infty \right] = 0$$

Seja  $\eta_M$  é uma sequência de variáveis aleatórias com distribuição idêntica e independente, de média 0, variância 1 e terceiro momento finito ( $E[\eta_M^3(i)] < \infty$  para todo  $i$ ).

Com isto, definimos  $x^M$  por :

$$\begin{aligned} x_{a+n+1}^M &= x_{a+n}^M + X_0^M(x_{a+n}^M) \frac{1}{M} + X_1^M(x_{a+n}^M) \frac{\eta_M(a+n+1)}{M^{\frac{1}{2}}} \\ x^M(a) &= x_a \end{aligned}$$

e estendemos a um processo estocástico de tempo contínuo dado por:

$$x^M(t) = x^M(a+n), \quad a+n \leq t < a+n+1$$

Com esta estrutura temos o seguinte resultado (GARD, 1988, p. 166, 167).

**Teorema 8 (Turelli)** Com as hipóteses acima, se  $x_t$  é solução da equação

$$dx_t = X_0(x_t)dt + X_1(x_t)dB_t$$

então

$$\lim_{M \rightarrow \infty} \mathbb{P} [|x^M(t) - x(t)| > \epsilon] = 0.$$



Vamos mostrar agora que o esquema de Euler proposto acima para nossa equação satisfaz as condições do teorema de Turelli. Repetimos que aqui só vamos considerar o primeiro passo (que corresponde para  $M = 1$  e para partições no tempo em intervalos de comprimento 1), porém se aumentando o valor de  $M$  teremos aproximações mais precisas.

Assim, na equação do modelo de crescimento populacional que estamos considerando temos que

- As funções

$$X_0(x) = rx(k - \alpha x), \quad X_1(x) = \beta x, \quad x_0 = N,$$

satisfazem as hipóteses do teorema.

- O valor de  $M$  está associado a partição do intervalo. No nosso caso, como dito acima, vamos somente trabalhar com  $M = 1$  e  $\eta_1 = (S_j)$  como na simulação do movimento browniano acima. Porém, no caso genérico teríamos que, para cada  $M$ ,  $\eta_M = (S_j)$  é uma sequência de variáveis aleatórias independentes com distribuição normal com média 0 e variância 1. De fato, como

$$t_{i+1} - t_i = \frac{1}{M},$$

temos que

$$\frac{\eta_M(i+1)}{\sqrt{M}} = \frac{1}{\sqrt{M}} S_{i+1} = \sqrt{t_{i+1} - t_i} S_{i+1} = (B_{t_{i+1}} - B_{t_i}).$$

Decorre disto que o terceiro momento da  $\eta_M(i)$  é finito para cada  $i$ .

Agora, para poder utilizar o teorema de Turelli, só resta mostrar que o limite no  $\infty$  é atingível. Para isto vemos que a solução do processo satisfaz

$$x_t = \frac{e^{(rk - \frac{1}{2}\beta^2)t + \beta B_t}}{\frac{1}{N} + r\alpha \int_0^t e^{(rk - \frac{1}{2}\beta^2)s + \beta B_s} ds} \leq N e^{(rk - \frac{1}{2}\beta^2)t + \beta B_t}.$$

agora, utilizando que  $x_t > 0$  e a desigualdade de Chebyshev (OKSENDAL, 1997, p. 16), temos que

$$\begin{aligned} \mathbb{P}[x_t > \alpha] &\leq \frac{1}{\alpha} \mathbb{E}[x_t] \\ &\leq \frac{1}{\alpha} \mathbb{E} \left[ N e^{(rk - \frac{1}{2}\beta^2)t + \beta B_t} \right] \\ &= \frac{N}{\alpha} e^{rkt}. \end{aligned}$$

Aqui foi utilizado o seguinte resultado.

### Lema 9

$$M_t = e^{(rk - \frac{1}{2}\beta^2)t + \beta B_t}$$

satisfaz  $\mathbb{E}[M_t] = e^{rkt}$ .

*Demonstração.* Utilizamos a fórmula de Itô para

$$f(t, x) = e^{(rk - \frac{1}{2}\beta^2)t + \beta x},$$



então

$$f(t, B_t) = 1 + rk \int_0^t f(s, B_s) ds + \beta \int_0^t f(s, B_s) dB_s.$$

Utilizando que

$$\mathbb{E} \left[ \beta \int_0^t f(s, B_s) dB_s \right] = 0,$$

obtemos

$$\mathbb{E}[f(t, B_t)] = 1 + rk \int_0^t \mathbb{E}[f(s, B_s)] ds.$$

De onde segue que,

$$\mathbb{E}[f(t, B_t)] = e^{rkt}.$$

□

Com isto, temos mostrado que, para todo  $t > 0$ , vale

$$\mathbb{P}[x_t = \infty] = \lim_{\alpha \rightarrow \infty} \mathbb{P}[x_t > \alpha] = 0.$$

Portanto o limite no  $\infty$  é inatingível.

Assim sendo, todas as hipóteses do Teorema de Turelli são satisfeitas e ele pode ser aplicado. Então, a simulação  $x^M$  que está associada ao esquema de Euler apresentado, converge em lei à  $x_t$  se  $M \rightarrow \infty$ .

Aqui só vamos simular o caso em que  $M = 1$  pois para valores maiores de  $M$  o tempo computacional é muito maior. A seguir, mostramos na figura 2 uma simulação da solução  $x_t$  com os seguintes parâmetros

$$N = 700, \quad r = 0.0002, \quad \alpha = 1, \quad k = 1000 \quad \text{e} \quad \beta = 0.01.$$

Por se tratar de uma função exponencial, foi utilizado escala logarítmica no eixo y para melhor visualização do processo.




Figura 2: 10000 caminhos  $x^1$  com  $l = 100$

Finalizamos o trabalho mostrando a consistência da simulação com a teoria vista na seção anterior. De fato, após simular os caminhos, foi observada a distribuição de  $x^1$  em  $t = 99$ . Este valor de  $t$  se corresponde com a centésima marca do tempo e consideramos um valor de tempo suficientemente grande já que  $t = \infty$  não é possível de ser simulado. Comparamos assim a distribuição de probabilidade obtida dentre os 10.000 caminhos no tempo  $t_{99}$  e a distribuição dada pela medida invariante  $\rho(x)$  obtida na seção anterior. Como apresentado abaixo na figura 3, é possível observar que a distribuição simulada é muito semelhante à distribuição teórica  $\rho(x)$ . Na figura, o intervalo  $[920, 1080]$  é particionado em 100 partes iguais e é computada a frequência normalizada em que  $x^1$  atinge cada um destes subintervalos para o valor de  $t_{99}$ . Isto gera a distribuição em azul.






Figura 3: distribuição discreta de probabilidade em  $t_{99}$  e distribuição da densidade da medida invariante  $\rho(x)$

## 5 Apêndices

Neste apêndice apresentamos o código construído em python para as simulações, além do código, é disponibilizado através do github, um notebook criado originalmente no google colab onde é possível se ver a execução passo a passo e variar parâmetros para se observar os resultados obtidos. Fazendo testes experimentais com o intuito de melhor estimar os parâmetros para uma simulação apresentável, foi possível se observar que é interessante para a simulação que  $rk < 1$ , que  $\beta$  seja da ordem de  $\frac{\alpha rk}{10}$  para  $\alpha > 0$  e da ordem de  $rk$  para  $\alpha = 0$  pois para valores fora dessa faixa o ruído é predominante na simulação e se faz necessário utilizar um número maior de simulações do movimento browniano (isto é, um valor  $> 10.000$ ) o que torna o tempo computacional muito maior.

### Código em python

```
import numpy
import math
from matplotlib import pyplot as plt
from scipy.stats import gamma
```



```

340 import numpy as np
341
342 #calculo de x_t
343 def x_t2(r, K, alpha, beta, x_0, lista):
344     out = [(lista[0][0], x_0)]
345     outQuad = [(lista[0][0], x_0**2)]
346     tamanho = len(lista)
347     for i in range(1, tamanho):
348         out.append((lista[i][0], out[i-1][1] + r*out[i-1][1]
349                     *(K-alpha*out[i-1][1])
350                     *(lista[i][0] - lista[i-1][0]) +
351                     beta*out[i-1][1]*(lista[i][1] - lista[i-1][1])))
352         outQuad.append((lista[i][0], out[i][1]**2))
353
354     return out, outQuad
355
356 #calculo esperanca dos caminhos simulados
357 def espSim(lista, pos):
358     aux=0
359     for i in range(len(lista)):
360         aux+=lista[i][pos][1]
361     return aux/len(lista)
362
363
364
365 alpha = 1
366 # parametros da simulacao
367 n = 10000
368 k = 100
369 dt=1
370 t = [i*dt for i in range(k+1)]
371
372 if alpha != 0:
373     r=0.0002
374     K=1000
375     beta=0.01
376     x_0=700
377 elif alpha == 0:
378     r=0.0002
379     K=1000
380     alpha=0
381     beta=0.2
382     x_0=2
383
384 B = [[0] for i in range(n)] #array com variaveis aleatorias
385 S = [[] for i in range(n)] #array com as variaveis aleatorias  $S \sim N(0,1)$ 
386

```



```

387 #simulacao movimentos brownianos
388 for j in range(n):
389     for i in range(k):
390         S[j].append(numpy.random.normal(0,1))
391
392 for j in range(n):
393     for i in range(k):
394         B[j].append(B[j][i] + dt**0.5*S[j][i])
395
396 #criacao de tuplas(tempo, movimento browniano)
397 lista = [[] for i in range(n)]
398 for j in range(n):
399     for i in range(k+1):
400         lista[j].append((t[i], B[j][i]))
401
402 plt.title('Movimento_browniano')
403 plt.xlabel('tempo')
404 plt.ylabel('B_t')
405
406 for i in range(n):
407     plt.plot(*zip(*lista[i]))
408
409 plt.title('Movimento_browniano')
410 plt.xlabel('tempo')
411 plt.ylabel('B_t')
412
413
414
415 #calculo da variavel aleatoria x_t
416 lista2 = [[] for i in range(n)]
417 lista3 = [[] for i in range(n)]
418 for j in range(n):
419     x, x2 = x_t2(r,K,alpha,beta,x_0, lista[j])
420     lista2[j] = x
421     lista3[j] = x2
422
423
424 for i in range(n):
425     plt.semilogy(*zip(*lista2[i]), zorder = 1)
426
427 #calculo esperanca simulada
428 espSimul = []
429 for i in range(k+1):
430     espSimul.append((t[i], espSim(lista2, i)))
431
432 espQuadSimul = []
433 for i in range(k+1):

```



```

434     espQuadSimul.append((t[i], espSim(lista3, i)))
435
436 sdevUp = [(t[i], espSimul[i][1] + (espQuadSimul[i][1] -
437                                     espSimul[i][1]**2)**0.5)
438            for i in range(len(espQuadSimul))]
439 sdevDown = [(t[i], espSimul[i][1] - (espQuadSimul[i][1] -
440                                     espSimul[i][1]**2)**0.5)
441              for i in range(len(espQuadSimul))]
442
443 #plot caminhos e esperancas
444 plt.title('Crescimento populacional,  $\alpha$ ='+str(alpha))
445 plt.xlabel('tempo')
446 plt.ylabel('log(Xt)')
447
448 plt.semilogy(*zip(*espSimul), linewidth=3, color='brown', zorder=2)
449 plt.semilogy(*zip(*sdevUp), linewidth=3, color='blue', zorder=2)
450 plt.semilogy(*zip(*sdevDown), linewidth=3, color='blue', zorder=2)
451
452 for i in range(n):
453     plt.semilogy(*zip(*lista2[i]), zorder=1)
454
455 legenda = []
456 legenda.append("Esperanca simulada")
457 legenda.append("Desvio padrao")
458
459
460 plt.legend(legenda)
461
462
463 if alpha != 0:
464     a, c = (2*r*K-beta**2)/(beta**2), 2*r*alpha/beta**2
465     aux = [lista2[i][k][1] for i in range(len(lista2))]
466
467     fig, ax = plt.subplots(1, 1)
468
469     x = np.linspace(925, 1075, 4000)
470     y1 = gamma.pdf(x, a=a, scale=1/c)
471     ax.plot(x, y1, "y-", label=(r'$\alpha=29, \beta=3$'))
472
473     ax.hist(aux, 100, density=True)
474
475     ax.set_title('Distribuicoes')
476     ax.set_xlabel('xt')
477     ax.set_ylabel('P(xt=xt)')
478
479     legenda2 = []
480     legenda2.append('dist teorica')

```



```
legenda2.append('dist_experimental')
```

```
ax.legend(legenda2)
```

```
print((2*r*K-beta**2)/(2*r*alpha))
```

O código está também disponível no github em:

<https://github.com/HitaloCesar/artigo-cres-pop/blob/main/simul.ipynb>

## 6 Agradecimentos

Hitalo Cesar Alves agradece ao CNPq pelo suporte dado via a bolsa PICME para seus estudos de iniciação científica.

Diego Sebastian Ledesma recebeu suporte financeiro da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior - Brasil (CAPES) - Finance Code 001 e Fapesp 2020/04426-6 e 2018/13481-0.

## 7 Referências Bibliográficas

GARD, T. C. **Introduction to stochastic differential equations**. New York: Marcel Dekker Inc, 1988.

KHASHMINSKII, R. **Stochastic stability of differential equations**. [cidade]: Springer, 2011. (Stochastic modelling and applied probability book series).

KUNITA, H. **Stochastic flows and stochastic differential equations**. Cambridge: Cambridge University Press, 1997.

OKSENDAL, B. **Stochastic differential equations: an introduction with applications**. Berlin, Heidelberg: Springer-Verlag, 1997.

POLANSKY, P. Invariant distributions for multipopulation models in random environments, **Theor. Pop. Biol.**, v. 16, n. 1, p. 25-34, 1979.

SONDERMAN, D. **Introduction to stochastic calculus for finance**. Berlin, Heidelberg: Springer-Verlag, 2006. (Lecture Notes in Economics and Mathematical Systems, 579).